

# Introduction to mathematical statistics ゼミ

## (第 1b, 2b 回)

担当: 伊藤真道

未定

(おそらく講義しないので各自読んでおいてください)

## 1 Chap.1. Probability and Distribution

### 1.10 Important Inequalities / 重要な不等式

この節では、期待値に関するいくつかの有名な不等式について論ずる。ここで、論じた不等式は以降の章で利用されている。

**定理 1.1.**  $X$  を確率変数とし、 $m$  を正整数とし、 $E[X^m]$  の存在を仮定する。もし、 $k \leq m$  なる正整数  $k$  が存在するならば、 $E[X^k]$  が存在する。

**証明 1.1.** ここでは連続の場合についてのみ考える。 $f(x)$  を  $X$  の確率密度関数とすると、

$$\begin{aligned} E[X^k] &\leq E[|X|^k] = \int_{-\infty}^{\infty} |x|^k f(x) dx \\ &= \int_{|x| \leq 1} |x|^k f(x) dx + \int_{|x| > 1} |x|^k f(x) dx \\ &\leq \int_{|x| \leq 1} f(x) dx + \int_{|x| > 1} |x|^m f(x) dx \\ &\leq \int_{-\infty}^{\infty} f(x) dx + \int_{-\infty}^{\infty} |x|^m f(x) dx \\ &\leq 1 + E[|X|^m] < \infty \end{aligned}$$

となるため、 $E[X^k]$  は存在する

□

定理 1.10.2(マルコフの不等式), 定理 1.10.3(チェビシェフの不等式) に関しては, 第 1 回の伊藤の資料を参照.

**定義 1.1.** 凸関数 (*convex function*), 狭義凸 (*strictly convex*)  $-\infty \leq a < b \leq \infty$  なる区間  $(a, b)$  上で定義された関数が, 凸関数であるとは, 任意の  $x, y \in (a, b), 0 < \gamma < 1$  に対して,

$$\phi[\gamma x + (1 - \gamma)y] \leq \gamma\phi(x) + (1 - \gamma)\phi(y)$$

が成り立つことを言う. もし, 上の不等式が, 狭義 (*strict*) な大小関係 (=左辺と右辺が” $<$ ”の大小関係となること) ならば, 関数  $\phi$  は狭義凸 (*strictly convex*) であると言う.

jnote;

$\phi$  の一階微分, 二階微分 (それぞれ  $\phi', \phi''$  で表す) が存在するとすると, 以下の定理が成り立つ

**定理 1.2.** もし  $\phi$  が  $(a, b)$  上で微分可能ならば,

1. 任意の  $a < x < y < b$  に対して,  $\phi'(x) \leq \phi'(y)$  が成り立つとき,  $\phi$  は凸である
2. 任意の  $a < x < y < b$  に対して,  $\phi'(x) < \phi'(y)$  が成り立つとき,  $\phi$  は狭義凸である

さらに,  $\phi$  が  $(a, b)$  上で二階微分可能ならば,

1.  $a < x < b$  なる任意の  $x$  について  $\phi''(x) \geq 0$  が成り立つとき,  $\phi$  は凸である
2.  $a < x < b$  なる任意の  $x$  について  $\phi''(x) > 0$  が成り立つとき,  $\phi$  は狭義凸である

証明は, 例えば Hewitt and Stromberg(1965)などを参照. この凸性から, 大変重要な確率不等式が得られる.

jnote;

**定理 1.3.** イェンセンの不等式 (*Jensen's Inequality*) もし、 $\phi$  が、ある開区間  $I$  上で凸であり、なおかつ、 $X$  が有限の期待値を持ち、台 (=関数の値が 0 とならない点の集合、ここで関数とは確率変数のことを指す。) が区間  $I$  に含まれているような確率変数であるとするならば、

$$\phi[E(X)] \leq E[\phi(X)]$$

となる。もし、 $\phi$  が狭義凸ならば、 $X$  が定数確率変数でない限り、不等号は、狭義なものとなる。

**証明 1.2.** 以下の証明では、 $\phi$  が二階の導関数を持つと仮定するが、一般的な証明では、凸性のみが仮定されている。 $\phi(x)$  を  $\mu = E[X]$  の周りで 2 次までのテイラー展開を行うと、

$$\phi(x) = \phi(\mu) + \phi'(\mu)(x - \mu) + \frac{\phi''(\xi)(x - \mu)^2}{2}$$

となる。ここで、 $\xi$  は  $x$  と  $\mu$  の間にあるとする。上の関数の右辺第三項は非負であるため、

$$\phi(x) \geq \phi(\mu) + \phi'(\mu)(x - \mu)$$

を得る。ここで、両辺の  $X$  に関する期待値をとることで、定理の不等式が得られる。この不等式は、任意の  $x \in (a, b)$  について  $\phi''(x) > 0$  であり、 $X$  が定数でないとき、狭義である。

□

**例 1.4.** 調和平均 (*Harmonic Mean*) と幾何平均 (*Geometric Mean*)  $\{a_1, \dots, a_n\}$  を正の数の集合とする。それぞれの  $a_1, \dots, a_n$  に対して、重み  $1/n$  (=確率のようなものと思ってください) を与えることで、確率変数  $X$  に対する分布を構成する。この場合、 $X$  の平均は算術平均 (*arithmetic*

mean,  $AM$ ) であり,  $E(X) = n^{-1} \sum_{i=1}^n a_i$  で与えられる.  $-\log x$  は凸関数である (確かめてみて) ことから, イェンセンの不等式を利用して,

$$-\log\left(\frac{1}{n} \sum_{i=1}^n a_i\right) \leq E[-\log X] = -\frac{1}{n} \sum_{i=1}^n \log a_i = -\log(a_1 a_2 \cdots a_n)^{1/n}$$

となるが, これを変形すると

$$\log\left(\frac{1}{n} \sum_{i=1}^n a_i\right) \geq \log(a_1 a_2 \cdots a_n)^{1/n}$$

が得られる. さらに,  $\log(x)$  の単調性から,

$$(a_1 a_2 \cdots a_n)^{1/n} \leq \frac{1}{n} \sum_{i=1}^n a_i$$

となる. 左辺を幾何平均 (*Geometric Mean, GM*) と呼ぶ. 以上の不等式は, 正の数の有限集合に対して,  $GM \leq AM$  となることを表している. 次に,  $a_i$  を  $1/a_i$  で置き換えることを考える. すると,

$$\frac{1}{n} \sum_{i=1}^n \frac{1}{a_i} \geq \left(\frac{1}{a_1} \frac{1}{a_2} \cdots \frac{1}{a_n}\right)^{1/n}$$

さらに, 両辺の逆数をとって

$$\frac{1}{\frac{1}{n} \sum_{i=1}^n \frac{1}{a_i}} \leq (a_1 a_2 \cdots a_n)^{1/n}$$

が得られる. 左辺を調和平均 (*Harmonic Mean, HM*) と呼ぶ. 以上をまとめると, 正の数の有限集合に対して,

$$HM \leq GM \leq AM$$

なる大小関係が成立する.

[note]

## 2 Chap.2. Multivariate Distribution

### 2.6 Extension to Several Random Variables / 複数の確率変数への拡張

2.6.1 までは，第二回の山本さんの資料と伊藤の資料を参照．

#### 2.6.1 Multivariate Variance-Covariance Matrix / 分散共分散行列

ここでは，確率変数が  $n$  変数である場合を考える． $\mathbf{X} = (X_1, \dots, X_n)'$  を  $n$  次元確率変数ベクトルとする． $n$  次元確率変数ベクトルに対して，期待値は，要素である確率変数それぞれの期待値を並べたものとして，

$$E[\mathbf{X}] = (E[X_1], \dots, E[X_n])$$

のように定義される．確率変数ベクトルの拡張として，確率変数行列を考える． $m \times n$  行列  $\mathbf{W}$  が確率変数を要素にもつ行列とする．確率変数行列の期待値は，確率変数ベクトルと同様に，

$$E[\mathbf{W}] = [E(W_{ij})], 1 \leq i \leq m, 1 \leq j \leq n$$

のように定義される．期待値作用素の線型性から，以下の定理が成り立つ．

**定理 2.1.**  $m \times n$  行列  $\mathbf{W}_1, \mathbf{W}_2$  を確率変数行列とし， $A_1, A_2$  を  $k \times m$  の， $B$  を  $n \times l$  の定数行列とする．このとき，

$$\begin{aligned} E[A_1 \mathbf{W}_1 + A_2 \mathbf{W}_2] &= A_1 E[\mathbf{W}_1] + A_2 E[\mathbf{W}_2] \\ E[A_1 \mathbf{W}_1 B] &= A_1 E[\mathbf{W}_1] B \end{aligned}$$

が成立する．

**証明 2.1.** 一つ目の等式に関して，左辺の  $(i, j)$  要素は，

$$\begin{aligned} & E\left[\sum_{s=1}^m a_{1is} W_{1sj} + \sum_{s=1}^m a_{2is} W_{2sj}\right] \\ &= \sum_{s=1}^m a_{1is} E[W_{1sj}] + \sum_{s=1}^m a_{2is} E[W_{2sj}] \\ & (= a_{1i.} E[W_{1.j}] + a_{2i.} E[W_{2.j}] \text{ (ベクトルで書いた場合)}) \end{aligned}$$

のようにかける．これを，全ての  $(i, j)$  の組み合わせについて考えることで，一つ目の等式が成立することがわかる．  $\square$

二つ目の等式に関して，左辺の  $(i, j)$  要素は，

$$\begin{aligned} & E\left[\sum_{h=1}^n \sum_{s=1}^m a_{1is} W_{1sh} b_{hj}\right] \\ &= \sum_{h=1}^n \sum_{s=1}^m a_{1is} E[W_{1sh}] b_{hj} \end{aligned}$$

のようにかける．これを全ての  $(i, j), 1 \leq i \leq k, 1 \leq j \leq l$  について考えることで，二つ目の等式が成り立つことがわかる．  $\square$

[note]

$\mathbf{X} = (X_1, \dots, X_n)'$  が  $n$  次元確率変数ベクトルであり，その要素の分散が存在する，つまり， $\sigma_i^2 = V[X_i] < \infty$  とする．平均  $\mu = E[\mathbf{X}]$  を用いて，分散共分散行列を以下のように定義する．

$$Cov(\mathbf{X}) = E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)'] = [\sigma_{ij}]$$

$Cov(\mathbf{X})$  の対角成分は  $\sigma_{ii} = \sigma_i^2 = Var(X_i)$  であり，非対角成分は  $\sigma_{ij} = Cov(X_i, X_j), i \neq j$  である．

**定理 2.2.**  $\mathbf{X} = (X_1, \dots, X_n)'$  が  $n$  次元確率変数ベクトルであり，その要素の分散が存在する，つまり， $\sigma_i^2 = V[X_i] < \infty$  とする． $A$  を  $m \times n$  の定数行列とする．この時，

$$Cov(\mathbf{X}) = E[\mathbf{X}\mathbf{X}'] - \mu\mu'$$

$$Cov(A\mathbf{X}) = ACov(\mathbf{X})A'$$

が成立する．

**証明 2.2.** 一つ目の等式について，

$$\begin{aligned} Cov(\mathbf{X}) &= E[(\mathbf{X} - \mu)(\mathbf{X} - \mu)'] \\ &= E[\mathbf{X}\mathbf{X}' - \mu\mathbf{X}' - \mathbf{X}\mu' + \mu\mu'] \\ &= E[\mathbf{X}\mathbf{X}'] - \mu E[\mathbf{X}'] - E[\mathbf{X}]\mu' + \mu\mu' \\ &= E[\mathbf{X}\mathbf{X}'] - \mu\mu' \end{aligned}$$

$\square$

二つ目の等式に関して，

$$\begin{aligned} Cov(A\mathbf{X}) &= E[(A\mathbf{X} - A\mu)(A\mathbf{X} - A\mu)'] \\ &= E[A(\mathbf{X} - \mu)(\mathbf{X} - \mu)'A'] \\ &= AE[(\mathbf{X} - \mu)(\mathbf{X} - \mu)']A' = ACov(\mathbf{X})A' \end{aligned}$$

$\square$

note

全ての分散共分散行列は，半正定値 (*positive semi-definite*) 行列である．つまり， $a' \text{Cov}(\mathbf{X})a \geq 0, \forall a \in \mathbb{R}^n$  である．ある  $n \times 1$  ベクトル  $a$  を用いて， $Y = a'\mathbf{X}$  のような確率変数を構成する．このとき，分散の非負性から，

$$0 \leq V(Y) = V(a'\mathbf{X}) = a' \text{Cov}(\mathbf{X})a$$

となり， $\text{Cov}(\mathbf{X})$  の半正定値性が示された．

note

## 2.7 Transformations for Several Random Variables / 複数の確率変数の変換

本節では， $n$  変数の場合の変数変換について説明する．変数変換とは，単に置換積分のことなので，練習したければ，微分積分の教科書の演習を解けば良いのではないのでしょうか．さて，以下の形式の積分を考える．

$$\int \cdots \int_A f(x_1, x_2, \dots, x_n) dx_1 dx_2 \cdots dx_n$$

ここで， $A \subset \mathcal{S}$ ， $\mathcal{S}$  は確率変数  $X_1, \dots, X_n$  の取りうる値の空間である．様々な理由で， $x_1, \dots, x_n$  を

$$y_1 = u_1(x_1, \dots, x_n), \dots, y_n = u_n(x_1, \dots, x_n)$$

のように変換してから積分することがある．ここで， $y_1, \dots, y_n$  の空間を  $\mathcal{T}$ ，その部分空間を  $B$  とする．

様々な理由の例

- $Y = X_1 + X_2$  などの分布を計算したい
- 変換した方が積分計算が楽になることがある (数 3 の極座標変換とか?)

先ほどの  $x_1, \dots, x_n$  の空間  $\mathcal{S}$  から  $y_1, \dots, y_n$  の空間  $\mathcal{T}$  への変換  $u_1(\cdot), \dots, u_n(\cdot)$  の 1 対 1 対応の逆変換

$$x_1 = w_1(y_1, \dots, y_n), \dots, x_n = w_n(y_1, \dots, y_n)$$

を考える． $w_1, \dots, w_n$  の一階の導関数が連続であり，空間  $\mathcal{S}$  と空間  $\mathcal{T}$  の面積比 (ここ，雑な表現です．厳密には違います) を表すヤコビアン (Jacobian) と呼ばれる  $n \times n$  の行列式 (determinant)

$$J = \begin{vmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} & \cdots & \frac{\partial x_1}{\partial y_n} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} & \cdots & \frac{\partial x_2}{\partial y_n} \\ \vdots & \vdots & & \vdots \\ \frac{\partial x_n}{\partial y_1} & \frac{\partial x_n}{\partial y_2} & \cdots & \frac{\partial x_n}{\partial y_n} \end{vmatrix}$$

が  $\mathcal{T}$  で 0 でないとする．このとき，冒頭の積分は，

$$\begin{aligned} & \int \cdots \int_A f(x_1, x_2, \dots, x_n) dx_1 dx_2 \cdots, dx_n \\ &= \int \cdots \int_B f[w_1(y_1, y_2, \dots, y_n), w_2(y_1, y_2, \dots, y_n), \dots, w_n(y_1, y_2, \dots, y_n)] |J| dy_1 dy_2 \cdots, dy_n \end{aligned}$$

のように変換できる． $X_1, \dots, X_n$  の同時密度関数が  $f(x_1, \dots, x_n)$  の時， $Y_1 = u_1(X_1, \dots, X_n), \dots, Y_n = u_n(X_1, \dots, X_n)$  の同時密度関数は  $(y_1, \dots, y_n) \in \mathcal{T}$  上で，

$$g(y_1, \dots, y_n) := f(w_1(y_1, \dots, y_n), \dots, w_n(y_1, \dots, y_n)) |J|$$

で与えられる．また， $(y_1, \dots, y_n) \in \mathcal{T}$  以外の領域では 0 である．

抽象的な話題になったので，具体例として，以下の簡単な問題を解いてみてください．

**例 2.1.**  $0 < x < 1, 0 < y < 1$  の時， $u = x + y, v = y$  と変換するときの面積比 (=ヤコビアン) を求めよ．変換後の  $u, v$  の領域についても求めよ．

[以下，解答用の空白]



次に、一対一の逆変換の構成が容易でないケースについて紹介する． $X$  がコーシー分布 (Cauchy distribution) の密度関数

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad -\infty < x < \infty$$

を持つとし、 $Y = X^2$  とする．このとき、 $X$  の空間は  $\mathcal{S} := \{x | -\infty < x < \infty\}$  であり、 $Y$  の空間は  $\mathcal{T} := \{y | 0 \leq y < \infty\}$  である．この変換は、 $y = 0$  を除いて、ある一つの  $y$  の値に対して、2 つの  $x \in \mathcal{S}$  が対応しているため、一対一対応ではない．このようなケースには、一対一の対応にするために  $X$  の空間を複数の排反な空間に分割することで対処する．例えば、今回のケースでは、 $\mathcal{S} := \{x | -\infty < x < \infty, x \neq 0\}$ 、 $f(0) = 0$  と再定義し、 $A_1 := \{x | -\infty < x < 0\}$ 、 $A_2 := \{x | 0 < x < \infty\}$  のように分割する．こうすると、 $x$  が正の場合には、逆変換  $x = -\sqrt{y}$  が  $A_1, \mathcal{T}$  を一対一に結びつけ、 $x = \sqrt{y}$  が  $A_2, \mathcal{T}$  を一対一に結びつける．ここで、 $A_3 := \{x | x = -\sqrt{y}, y \in B\} \subset A_1$ 、 $A_4 := \{x | x = \sqrt{y}, y \in B\} \subset A_2$  と定義すると、 $Y \in B$  の確率は、

$$\begin{aligned} P(Y \in B) &= P(X \in A_3) + P(X \in A_4) \\ &= \int_{A_3} f(x) dx + \int_{A_4} f(x) dx \end{aligned}$$

となる．領域  $A_3$  から  $B$  への変換でのヤコビアン  $J_1$  は  $dx = -1/(2\sqrt{y})$ 、領域  $A_4$  から  $B$  への変換でのヤコビアン  $J_2$  は  $dx = 1/(2\sqrt{y})$  であることから、

$$\begin{aligned} P(Y \in B) &= \int_B f(-\sqrt{y}) \left| -\frac{1}{2\sqrt{y}} \right| dy + \int_B f(\sqrt{y}) \left| \frac{1}{2\sqrt{y}} \right| dy \\ &= \int_B [f(-\sqrt{y}) + f(\sqrt{y})] \frac{1}{2\sqrt{y}} dy \end{aligned}$$

となる．よって  $Y$  の密度関数は、

$$g(y) = \frac{1}{2\sqrt{y}} [f(-\sqrt{y}) + f(\sqrt{y})], \quad y \in \mathcal{T}$$

であり、これと、 $f(x)$  がコーシー分布であることに注意すると、

$$g(y) = \begin{cases} \frac{1}{\pi(1+y)\sqrt{y}} & 0 < y < \infty \\ 0 & elsewhere \end{cases}$$

となることがわかる．これは自由度 1 のカイ二乗分布の密度関数である．つまり以上の結果から，

コーシー分布の  $Y = X^2$  変換 = 自由度 1 のカイ二乗分布

が示された．変数変換では一対一対応となるよう，領域を分割することが重要である．

jnotej

## 2.8 Linear Combination of Random Variables / 確率変数の線型結合

$(X_1, \dots, X_n)'$  をランダム試行の確率変数ベクトルとする．現実世界では，標本平均  $\bar{X} = 1/n \sum_{i=1}^n X_i$  や標本分散  $S^2 = 1/n \sum_{i=1}^n (X_i - \bar{X})^2$  などのように，確率変数ベクトルの関数  $T = T(X_1, \dots, X_n)$  が頻繁に興味の対象となる．この節では，これらの変数の  $\mathbf{a} = (a_1, \dots, a_n)'$  による線型結合

$$T = \sum_{i=1}^n a_i X_i$$

を考える．

**定理 2.3.**  $T = \sum_{i=1}^n a_i X_i$  とする．  $E[|X_i|] < \infty$ ,  $i = 1, \dots, n$  のもとで，

$$E[T] = \sum_{i=1}^n a_i E[X_i]$$

である．

**証明 2.3.** 期待値の線形性から明らかである． □

␣note␣

定理 2.4.  $T = \sum_{i=1}^n a_i X_i$ ,  $W = \sum_{i=1}^m b_i Y_i$  とする. もし,  $E[|X_i^2|] < \infty$ ,  $E[|Y_j^2|] < \infty$ ,  $i = 1, \dots, n, j = 1, \dots, m$  であるならば,

$$\text{Cov}(T, W) = \sum_{i=1}^n \sum_{j=1}^m a_i b_j \text{Cov}(X_i, Y_j)$$

である.

証明 2.4.

$$\begin{aligned} \text{Cov}(T, W) &= E[(T - E[T])(W - E[W])'] \\ &= E\left[\left(\sum_{i=1}^n a_i (X_i - E[X_i])\right)\left(\sum_{j=1}^m b_j (Y_j - E[Y_j])\right)'\right] \\ &= E\left[\sum_{i=1}^n \sum_{j=1}^m a_i b_j (X_i - E[X_i])(Y_j - E[Y_j])'\right] \\ &= \sum_{i=1}^n \sum_{j=1}^m a_i b_j E[(X_i - E[X_i])(Y_j - E[Y_j])'] \\ &= \sum_{i=1}^n \sum_{j=1}^m a_i b_j \text{Cov}(X_i, Y_j) \end{aligned}$$

□

␣note␣

系 2.1.  $T = \sum_{i=1}^n a_i X_i$  とする.  $E[|X_i|] < \infty$ ,  $i = 1, \dots, n$  のもとで,

$$\text{Var}(T) = \text{Cov}(T, T) = \sum_{i=1}^n a_i^2 \text{Var}(X_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j)$$

証明 2.5. 定理 2.4 にて  $W$  を  $T$  に置き換えると,

$$\begin{aligned} \text{Var}(T) &= \text{Cov}(T, T) = \sum_{i=1}^n \sum_{j=1}^n a_i a_j \text{Cov}(X_i, X_j) \\ &= \sum_{i=1}^n a_i^2 \text{Cov}(X_i, X_i) + \sum_{i=1}^n \sum_{j \neq i} a_i a_j \text{Cov}(X_i, X_j) \\ &= \sum_{i=1}^n a_i^2 \text{Var}(X_i) + 2 \sum_{i < j} a_i a_j \text{Cov}(X_i, X_j) \end{aligned}$$

□

[note]

系 2.2. もし  $X_1, \dots, X_n$  が互いに独立な確率変数であり, 有限の分散を持つならば,

$$\text{Var}(T) = \sum_{i=1}^n a_i^2 \text{Var}(X_i)$$

証明 2.6.  $X_1, \dots, X_n$  が互いに独立な確率変数であるとき, 系 2.1 で  $\text{Cov}(X_i, X_j) = 0$  となることから, 系 2.2 をえる. □

[note]

もし  $X_1, \dots, X_n$  が互いに独立で同一な分布に従う (independent and identically distributed, iid) 確率変数ならば, この変数は, 共通の分布から, サイズ  $n$  の無作為標本を構成しているという.

[note]

**定義 2.1.** 標本平均と不偏標本分散標本平均  $\bar{X}$ , 不偏標本分散  $S^2$  はそれぞれ, 以下のように定義される.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (1)$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (2)$$

**定理 2.5.** 標本平均の期待値, 分散はそれぞれ,

$$E[\bar{X}] = \mu \quad (3)$$

$$V[\bar{X}] = \frac{\sigma^2}{n} \quad (4)$$

で定義され, 不偏分散の期待値は,

$$E[S^2] = \sigma^2$$

となる.

**証明 2.7.** 簡単 & 統計勉強してる人の中でこの証明は常識なので, 各自証明してください. わからない場合は, 「標本平均の期待値, 分散」とか, 「不偏標本分散の不偏性」とかで検索したら, 模範解答がわんさか出てくると思うのでそれ参考にしてください.

[note]