

# Introduction to mathematical statistics ゼミ

## (第?回)

担当: 伊藤真道

未定

### 3 Chap.3 Some Special Distributions

#### 3.5 The Multivariate Normal Distribution

(Dくんがやってくれたところの続きの残ってる部分だけです。まずは軽い復習から)  
 $Z_1, \dots, Z_n \stackrel{iid}{\sim} N(0, 1)$  である確率変数からなる確率変数ベクトル  $\mathbf{Z} := (Z_1, \dots, Z_n)'$  の密度関数は、 $\mathbf{z} \in \mathbb{R}^n$  について

$$\begin{aligned} f_{\mathbf{Z}}(\mathbf{z}) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}z_i^2\right\} = \left(\frac{1}{2\pi}\right)^{n/2} \exp\left\{-\frac{1}{2}\sum_{i=1}^n z_i^2\right\} \\ &= \left(\frac{1}{2\pi}\right)^{n/2} \exp\left\{-\frac{1}{2}\mathbf{z}'\mathbf{z}\right\} \end{aligned} \quad (3.5.1)$$

と表されるのだった。 $Z_i \sim N(0, 1)$  であり、これらは、無作為標本 (=iid) であることから、 $\mathbf{Z}$  の平均と分散は、

$$E[\mathbf{Z}] = \mathbf{0}_n, \quad V[\mathbf{Z}] = I_n \quad (3.5.2)$$

である。また、 $N(0, 1)$  の mgf は  $E[e^{t_i Z_i}] = \exp(0 \cdot t_i + (1 \cdot t_i)^2/2) = \exp(t_i^2/2)$  であったことを思い出すと、 $Z_i$  が iid であることから、 $\mathbf{Z}$  の mgf は、

$$M_{\mathbf{Z}}(\mathbf{t}) = E[\exp(\mathbf{t}'\mathbf{Z})] = \exp\left\{\frac{1}{2}\mathbf{t}'\mathbf{t}\right\} \quad (3.5.3)$$

となる。特に二つ目の等号は間を飛ばしているので、気になる方は、私に聞くか、自分で調べてください。また、ここで、 $\mathbf{t} \in \mathbb{R}^n$  である。以上のような性質を持つ確率変数ベクトル  $\mathbf{Z}$  は  $n$  次元多変量標準正規分布  $N(\mathbf{0}_n, I_n)$  に従うといい、 $\mathbf{Z} \sim N(\mathbf{0}_n, I_n)$  と表す。

1 変数の場合と同様に、多変数の場合にも標準でない正規分布も存在する。それを紹介するために、 $n \times n$  半正定値対称行列 (=グラム行列, Gramian) $\Sigma$  を用意する。線形代数の初歩的な知見か

ら、 $\Sigma$  は常に、

$$\Sigma = \Gamma' \Lambda \Gamma \quad (3.5.4)$$

のように、固有値を対角成分として持つ対角行列  $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$  と、それに対応する固有ベクトルを列として持つ直交行列  $\Gamma'$  を用いて固有値分解を行うことができることがわかっている。但し、 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$  である。 $\Sigma$  の半正定値性から、 $\lambda_i$  は非負であり、 $\Lambda^{1/2} := \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n})$  を用いて、

$$\Sigma = \Gamma' \Lambda^{1/2} \Gamma \Gamma' \Lambda^{1/2} \Gamma = \Sigma^{1/2} \Sigma^{1/2}$$

のように表すことができる。ここで、グラム行列の平方根を

$$\Sigma^{1/2} := \Gamma' \Lambda^{1/2} \Gamma$$

と定義した。さらに、 $\Sigma$  が正定値行列 (= 全ての固有値  $> 0$ ) と仮定すると、

$$\left( \Sigma^{1/2} \right)^{-1} = \Gamma' \Lambda^{-1/2} \Gamma$$

と逆行列の計算が可能である。詳しくは、伊藤レクチャー第一回を参照。

さて、一般の多変量正規分布についての話に戻ろう。先ほどと同様の半正定値対称行列  $\Sigma$  と、 $n \times 1$  の定数ベクトル  $\boldsymbol{\mu}$  を用いて、 $\mathbf{Z} \sim N(\mathbf{0}_n, I_n)$  を変換することを考える。

$$\mathbf{X} := \Sigma^{1/2} \mathbf{Z} + \boldsymbol{\mu} \quad (3.5.8)$$

と定義された  $\mathbf{Z}$  の線形変換  $\mathbf{X}$  の平均、分散、mgf は、

$$E[\mathbf{X}] = \boldsymbol{\mu}, \quad V[\mathbf{X}] = \Sigma \quad (3.5.9)$$

$$M_{\mathbf{X}}(\mathbf{t}) = \exp(\mathbf{t}' \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}' \Sigma \mathbf{t}) \quad (3.5.10)$$

となる。証明は略。気になったら私に聞いてください。

もし、ここで、 $\Sigma$  が正定値行列ならば、 $\Sigma^{-1/2}$  が存在し、 $\mathbf{X}, \mathbf{Z}$  は一対一に対応し、 $\mathbf{X}$  を

$$\mathbf{Z} = \Sigma^{-1/2} (\mathbf{X} - \boldsymbol{\mu}), \quad \det(\Sigma^{-1/2}) = \det(\Sigma)^{-1/2}$$

と変換することで、 $\mathbf{Z}$  を求めることができる。以上から、多変量正規分布の密度関数は、

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}, \quad \text{for } \mathbf{x} \in \mathbb{R}^n \quad (3.5.12)$$

と表される。以上を一旦まとめる。

多変量正規分布の密度関数, 平均, 分散, mgf

多変量正規分布  $N(\boldsymbol{\mu}, \Sigma)$  の密度関数は,

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}, \text{ for } \mathbf{x} \in \mathbb{R}^n \quad (3.5.12)$$

であり, 平均, 分散は,

$$\begin{aligned} E[\mathbf{X}] &= \boldsymbol{\mu}, \\ V[\mathbf{X}] &= \Sigma \end{aligned}$$

であり, mgf は

$$M_{\mathbf{X}}(\mathbf{t}) = \exp(\mathbf{t}' \boldsymbol{\mu} + \frac{1}{2} \mathbf{t}' \Sigma \mathbf{t})$$

である.

jnotej

以下頻繁に利用される定理を紹介する. 証明は, 前回の D くん担当のゼミでやっているため, 省略するが, 気になる方は私に聞くか, テキストを読んでください.

Theorem 3.5.1

$\mathbf{X} \sim N_n(\boldsymbol{\mu}, \Sigma)$  とし,  $\mathbf{Y} := \mathbf{A}\mathbf{X} + \mathbf{b}$  という変換を考える. この時,  $\mathbf{Y} \sim N_m(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}')$  である.

証明は, mgf を使う.

jnotej

Corollary 3.5.1

Theorem 3.5.1 で  $A = [I_m : O_{mp}]$ ,

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix}, \boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

であったとする。この時、 $\mathbf{X}_1 = A\mathbf{X}$  であり、 $\mathbf{X}_1 \sim N_m(\boldsymbol{\mu}_1, \Sigma_{11})$  である。

証明は、Theorem 3.5.1 の結果を利用する。

note

Theorem 3.5.2

(上記のセッティングで、) $\mathbf{X}_1$  と  $\mathbf{X}_2$  が独立であるとは、 $\Sigma_{12} = O$  であることを言う。

証明は、 $\Sigma'_{12} = \Sigma_{21}$  であることに注意して、 $\mathbf{X}_1, \mathbf{X}_2$  の jmgf をみる。

note

Theorem 3.5.3

(上記のセッティングで、) $\Sigma$  が正定値行列であることを仮定する。この時、 $\mathbf{X}_1|\mathbf{X}_2$  の条件付き分布は、

$$N_m(\boldsymbol{\mu}_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{X}_2 - \boldsymbol{\mu}_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}) \quad (3.5.12)$$

となる。

以降面倒なので、ベクトルの太字はやめます。本当に面倒なので、その時の状況で判断してください。わからなかったら、書き方が悪い！と私を詰ってください。

**Proof 3.1.** まず、確率変数ベクトル  $W = X_1 - \Sigma_{12}\Sigma_{22}^{-1}X_2$  と  $X_2$  について考える。これらの確率変数ベクトルの分布は、 $X = [X_1, X_2]'$  の線形変換、

$$\begin{bmatrix} W \\ X_2 \end{bmatrix} = \begin{bmatrix} I_m & -\Sigma_{12}\Sigma_{22}^{-1} \\ O_m & I_p \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$$

によって得られる。つまり、Theorem 3.5.1(多変量正規分布に従う確率変数ベクトルの線形変換)

が適用できて、 $E[W] = \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}\mu_2$ ,  $E[X_2] = \mu_2$  であり、共分散行列は、

$$\begin{aligned} V[(W, X_2)'] &= \begin{bmatrix} I_m & -\Sigma_{12}\Sigma_{22}^{-1} \\ O_m & I_p \end{bmatrix} V[X] \begin{bmatrix} I_m & -\Sigma_{12}\Sigma_{22}^{-1} \\ O_m & I_p \end{bmatrix}' \\ &= \begin{bmatrix} I_m & -\Sigma_{12}\Sigma_{22}^{-1} \\ O_m & I_p \end{bmatrix} \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \begin{bmatrix} I_m & -\Sigma_{12}\Sigma_{22}^{-1} \\ O_m & I_p \end{bmatrix}' \\ &= \begin{bmatrix} \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} & O' \\ O & \Sigma_{22} \end{bmatrix} \end{aligned}$$

ここで、 $\Sigma_{12} = O$  から *Theorem 3.5.2* が適用できて、 $W, X_2$  は独立であることがわかる。よって、 $W|X_2$  の分布と、 $W$  の周辺分布は等しい。つまり、

$$W|X_2 \sim N_m(\mu_1 - \Sigma_{12}\Sigma_{22}^{-1}\mu_2, \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})$$

さらに、 $X_1|X_2 = W + \Sigma_{12}\Sigma_{22}^{-1}X_2|X_2 = W + \Sigma_{12}\Sigma_{22}^{-1}X_2$  から、再び、*Theorem 3.5.1* を適用して、

$$\begin{aligned} X_1|X_2 &\sim N_m(\mu_1 - \Sigma_{12}\Sigma_{22}^{-1}\mu_2 + \Sigma_{12}\Sigma_{22}^{-1}X_2, \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}) \\ &= N_m(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(X_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}) \quad \square \end{aligned}$$

(最初の  $W$  と  $X_2$  の導入とか天才すぎて自力で思いつかんやろ...)

[note]

#### Theorem 3.5.4

(Theorem 3.5.3 と同様にセッティングで。) 確率変数  $W$  を  $W := (X - \mu)' \Sigma^{-1} (X - \mu)$  と定義すると、

$$W \sim \chi_n^2$$

である。

**Proof 3.2.**  $\Sigma$  の正定値性から、 $\Sigma = \Sigma^{1/2}\Sigma^{1/2}$  とかける。これを用いて、 $Z = \Sigma^{-1/2}(X - \mu)$  に対して、*Theorem 3.5.1* を適用すると、 $Z \sim N_n(0_n, I_n)$  である。また、 $W = (X - \mu)' \Sigma^{-1} (X - \mu) = (X - \mu)' \Sigma^{-1/2} \Sigma^{-1/2} (X - \mu) = Z'Z = \sum_i^n Z_i^2$  とかけ、 $Z_i$  はそれぞれ独立であることに注意すると、定理の結果を得る。

[note]

### 3.5.1 Applications

$X \sim N_n(\mu, \Sigma)$  で,  $\Sigma$  は正定値行列とする. この時, 以前紹介したように,  $\Sigma = \Gamma' \Lambda \Gamma$  と固有値分解可能である.  $Y := \Gamma(X - \mu)$  と定義し,  $\Gamma \Sigma \Gamma' = \Lambda$  であることに注意すると,  $Y \sim N_n(0_n, \Lambda)$  である.  $\Lambda$  が対角行列であることから,  $Y_1, \dots, Y_n$  はそれぞれ独立であり,  $N(0, \lambda_i)$  という分布に従う. このように定義された確率変数ベクトル  $Y$  を 主成分 (principal components) と呼ぶ.

また, 確率変数ベクトルの 総変動 (Total Variation) とは, その成分の分散の総和である.  $X$  の総変動は,

$$TV(X) = \sum_{i=1}^n \sigma_i^2 = \text{tr} \Sigma = \text{tr} \Gamma' \Lambda \Gamma = \text{tr} \Lambda \Gamma \Gamma' = \sum_{i=1}^n \lambda_i = TV(Y)$$

と変形でき, 主成分  $Y$  と同一の総変動を持つことがわかる.

次に,  $Y$  の最初の成分  $Y_1 = v_1'(X - \mu)$  について考えよう. これは,  $(X - \mu)$  の成分の  $\|v_1\| = 1$  なる  $v_1$  による線型結合である. さらに, 別の  $(X - \mu)$  の線型結合を考える. 仮にこれを  $a'(X - \mu)$  とし, こちらも  $\|a\| = 1$  であるとする.  $\{v_1, v_2, \dots, v_n\}$  は  $\mathbb{R}^n$  の基底であり,  $a \in \mathbb{R}^n$  であることから, 何らかのスカラー  $(c_1, \dots, c_n)$  を用いて,  $a = \sum_{i=1}^n c_i v_i$  と書けるはずである. さらに,  $\{v_1, v_2, \dots, v_n\}$  は直交しているため,

$$a'v_i = \left( \sum_{j=1}^n c_j v_j \right)' v_i = c_i v_i' v_i = c_i$$

となる. 線形変換  $a'X$  の分散は,

$$\begin{aligned} \text{Var}(a'X) &= a' \Sigma a \\ &= \sum_{i=1}^n \lambda_i (a'v_i)^2 \\ &= \sum_{i=1}^n \lambda_i a_i^2 \leq \lambda_1 \sum_{i=1}^n a_i^2 = \lambda \|a\|^2 = \lambda_1 = \text{Var}(Y_1) \end{aligned} \quad (3.5.24)$$

よって,  $Y_1$  は直交ベクトル  $a$  による線形変換の中で最大の分散を持つ. そのため,  $Y_1$  は  $X$  の First principal component と呼ばれる.

#### Theorem 3.5.5

(上につらつら書いたセッティングで)  $j = 2, \dots, n$ ,  $i = 1, 2, \dots, j-1$  に対して,  $a \perp v_i$  なる直交ベクトルに関して,  $\text{Var}[a'X] \leq \lambda_j = \text{Var}[Y_j]$  となる.

notej