

# Introduction to mathematical statistics ゼミ

## (第?回)

担当: 伊藤真道

未定

## 6 Chap.6 Maximum Likelihood Methods

### 6.5 Multiparameter Case: Testing

今度は、未知パラメータが多次元ベクトルの時の仮説検定について考えよう。ここでも、 $X_1, \dots, X_n$  は、pdf として  $f(x; \boldsymbol{\theta})$  ( $\boldsymbol{\theta} \in \Omega \subset \mathbb{R}^p$ ) を持つ分布からの iid 標本とする。この節でも前節同様、正則条件を仮定した際は、(R0)-(R9) が満たされているものとする。仮説検定問題

$$H_0 : \boldsymbol{\theta} \in \omega \text{ v.s. } H_1 : \boldsymbol{\theta} \in \Omega \cap \omega^c \quad (6.5.1)$$

を考える。ただし、 $\omega \subset \Omega$  は  $q$  ( $0 < q \leq p$ ) 個の独立な制約  $g_1(\boldsymbol{\theta}) = a_1, \dots, g_q(\boldsymbol{\theta}) = a_q$  で定義される集合である。また、関数  $g_1, \dots, g_q$  は連続的に微分可能であるとする。このことは、 $\omega$  が  $p - q$  次元空間であることを示している。定理 6.1.1 から、パラメータの真値は尤度関数を最大化するということを考慮すると、検定統計量は、尤度の比

$$\Lambda = \frac{\max_{\boldsymbol{\theta} \in \omega} L(\boldsymbol{\theta})}{\max_{\boldsymbol{\theta} \in \Omega} L(\boldsymbol{\theta})} \quad (6.5.2)$$

となると直感的に考えられる。未知パラメータがスカラーの場合と同様に、 $H_0$  が正しいと、 $\Lambda$  は 1 に近づき、 $H_1$  が正しいなら、 $\Lambda$  は小さな値となる。

定理 6.5.1

$X_1, \dots, X_n$  が pdf として  $f(x; \theta)$  ( $\theta \in \Omega \subset \mathbb{R}^p$ ) を持つ分布からの iid 標本とする．正則条件を仮定する． $\hat{\theta}_n$  をパラメータ空間が全空間  $\Omega$  である際の尤度方程式の解の列とする．また， $\hat{\theta}_{0,n}$  をパラメータ空間が  $\omega$  ( $p - q$  dimension) に縮小された際の尤度方程式の解の列とする．帰無仮説のもとでの尤度と，対立仮説のもとでの尤度の比を

$$\Lambda = \frac{L(\hat{\theta}_0)}{L(\hat{\theta})} := \frac{L(\hat{\omega})}{L(\hat{\Omega})} \quad (6.5.4)$$

と表すと，尤度比検定の検定統計量  $T$  は

$$T := -2 \log \Lambda \xrightarrow{D} \chi^2(q) \quad (6.5.11)$$

となる．つまり， $T$  は漸近的に自由度  $q$  (帰無仮説のもとでパラメータが存在する空間の次元数) のカイ二乗分布に従う．

**証明 6.1.** 証明は，*Rao(1973)* をみてください．

スカラーの場合と同じように，パラメータが多次元となった場合にも，ワルド検定やスコア検定を行える．興味があったら，*Lehmann(1999)* を参照．

**例 6.1.**  $X_1, \dots, X_n \xrightarrow{iid} N(\mu, \sigma^2)$  とし，検定問題

$$H_0 : \mu = \mu_0 \text{ v.s. } H_1 : \mu \neq \mu_0$$

を考える． $\Omega = \{(\mu, \sigma^2) : -\infty < \mu < \infty, \sigma^2 > 0\}$ ， $\omega = \{(\mu_0, \sigma^2) : \sigma^2 > 0\}$  とした時の各最大尤度の尤度比  $\Lambda$  を求めよ．

解答

¡note!

## 6.6 The EM Algorithm

実データ分析にて、データの一部が欠損していることがよくある (ほんまに). 本節では, そういったケースにおいて最尤推定量を計算する手法である EM アルゴリズムを紹介する. さらに説明するので, より詳しく知りたい方は, McLachlan とかで検索してみたらいいと思う.

まず, サイズ  $n$  のアイテムを考える. ただし, この中で,  $n_1$  個のアイテムは観測され,  $n_2 = n - n_1$  個のアイテムは観測されないとする. 観測されたアイテムを  $\mathbf{X}' = (X_1, X_2, \dots, X_{n_1})$  として表し, 観測されないアイテムを  $\mathbf{Z}' = (Z_1, Z_2, \dots, Z_{n_2})$  と表す.  $X_i$  は pdf  $f(x|\theta), \theta \in \Omega$  の分布からの iid 標本とし, 観測されないアイテム  $Z_j$  と観測されるアイテム  $X_i$  は互いに独立と仮定する. また,  $g(x|\theta)$  で  $\mathbf{X}$  の同時密度を表し,  $h(\mathbf{x}, \mathbf{z}|\theta)$  で観測されたアイテム  $\mathbf{X}$  と観測されないアイテム  $\mathbf{Z}$  の同時分布を表し,  $k(\mathbf{z}|\theta, \mathbf{x})$  で, 観測されるデータの情報が与えられているもとの観測されないデータ条件付き分布を表すとする. 条件付き pdf の定義から,

$$k(\mathbf{z}|\theta, \mathbf{x}) = \frac{h(\mathbf{x}, \mathbf{z}|\theta)}{g(\mathbf{x}|\theta)} \quad (6.6.1)$$

である.  $L(\theta|\mathbf{x}) = g(\mathbf{x}|\theta)$  を観測された尤度関数と呼び,

$$L^c(\theta|\mathbf{x}, \mathbf{z}) = h(\mathbf{x}, \mathbf{z}|\theta) \quad (6.6.2)$$

を完全尤度関数と呼ぶ. 我々の目的は, 完全尤度  $L^c(\theta|\mathbf{x}, \mathbf{z})$  を用いて, 尤度関数  $L(\theta|\mathbf{x})$  を最大化することである.

(6.6.1) から, 任意の  $\theta_0 \in \Omega$  に対して,

$$\begin{aligned} \log L(\theta|\mathbf{x}) &= \int \log L(\theta|\mathbf{x}) k(\mathbf{z}|\theta_0, \mathbf{x}) d\mathbf{z} \\ &= \int \log g(\mathbf{x}|\theta) k(\mathbf{z}|\theta_0, \mathbf{x}) d\mathbf{z} \\ &= \int [\log h(\mathbf{x}, \mathbf{z}|\theta) - \log k(\mathbf{z}|\theta, \mathbf{x})] k(\mathbf{z}|\theta_0, \mathbf{x}) d\mathbf{z} \\ &= \int \log[h(\mathbf{x}, \mathbf{z}|\theta)] k(\mathbf{z}|\theta_0, \mathbf{x}) d\mathbf{z} - \int \log[k(\mathbf{z}|\theta, \mathbf{x}) k(\mathbf{z}|\theta_0, \mathbf{x})] d\mathbf{z} \\ &= E_{\mathbf{z}|\theta_0, \mathbf{x}}[\log L^c(\theta|\mathbf{x}, \mathbf{Z})|\theta_0, \mathbf{x}] - E_{\mathbf{z}|\theta_0, \mathbf{x}}[\log k(\mathbf{Z}|\theta, \mathbf{x})|\theta_0, \mathbf{x}] \end{aligned} \quad (6.6.3)$$

という結果が得られる. 特に第 1 項を

$$Q(\theta|\theta_0, \mathbf{x}) := E_{\mathbf{z}|\theta_0, \mathbf{x}}[\log L^c(\theta|\mathbf{x}, \mathbf{Z})|\theta_0, \mathbf{x}] \quad (6.6.4)$$

と定義し, これを  $Q$  関数と呼び, これは, EM アルゴリズムの E-step として知られている.  $\theta$  の最初の推定値を  $\hat{\theta}^{(0)}$  とし,  $\hat{\theta}^{(1)}$  を  $Q(\theta|\theta_0, \mathbf{x})$  を最大化する  $\theta$  の推定値とする. これを繰り返すと,  $\theta$  の推定値の数列  $\hat{\theta}^{(m)}$  が得られる. ここで, EM アルゴリズムの全体像を先にまとめておく.

Algorithm 6.6.1(EM アルゴリズム)

$\hat{\theta}^{(m)}$  を  $m$  番目のステップでの推定値とする． $m + 1$  番目の step での推定値を計算するために，

1. Expectation step:

$$Q(\theta|\hat{\theta}^{(m)}, \mathbf{x}) = E_{\mathbf{z}|\hat{\theta}^{(m)}, \mathbf{x}}[\log |^c(\theta|\mathbf{x}, \mathbf{Z})|\hat{\theta}^{(m)}, \mathbf{x}] \quad (6.6.5)$$

を計算する．

2.

$$\hat{\theta}^{(m+1)} = \operatorname{argmax}_{\theta} Q(\theta|\hat{\theta}^{(m)}, \mathbf{x}) \quad (6.6.6)$$

なる  $\theta$  を  $\hat{\theta}^{(m+1)}$  とする．

強い仮定のもとで， $m \rightarrow \infty$  の時， $\hat{\theta}^{(m)}$  は最尤推定量に確率収束することが知られています．このことは，ここでは示さないなので，調べててください．

定理 6.6.1

アルゴリズム 6.6.1 で定義された，推定値  $\hat{\theta}^{(m)}$  の数列は

$$L(\hat{\theta}^{(m+1)}|\mathbf{x}) \geq L(\hat{\theta}^{(m)}|\mathbf{x}) \quad (6.6.7)$$

を満たす．

**証明 6.2.**  $\hat{\theta}^{(m+1)}$  は  $Q(\theta|\hat{\theta}^m, \mathbf{x})$  を最大化するため，

$$Q(\hat{\theta}^{(m+1)}|\hat{\theta}^{(m)}, \mathbf{x}) \geq Q(\hat{\theta}^{(m)}|\hat{\theta}^{(m)}, \mathbf{x})$$

であり，これは，

$$E_{\mathbf{z}|\hat{\theta}^{(m)}, \mathbf{x}}[\log L^c(\hat{\theta}^{(m+1)}|\mathbf{x}, \mathbf{Z})] \geq E_{\mathbf{z}|\hat{\theta}^{(m)}, \mathbf{x}}[\log L^c(\hat{\theta}^{(m)}|\mathbf{x}, \mathbf{Z})] \quad (6.6.8)$$

と等しい．ただしここで，期待値は， $k(\mathbf{z}|\hat{\theta}^{(m)}, \mathbf{x})$  のもとでとられている．(6.6.3) から，

$$E_{\mathbf{z}|\hat{\theta}^{(m)}, \mathbf{x}}[\log k(\mathbf{Z}|\hat{\theta}^{(m+1)}, \mathbf{x})] \leq E_{\mathbf{z}|\hat{\theta}^{(m)}, \mathbf{x}}[\log k(\mathbf{Z}|\hat{\theta}^{(m)}, \mathbf{x})] \quad (6.6.9)$$

となることを示せば，証明完了である．イェンセンの不等式から，

$$\begin{aligned} E_{\mathbf{z}|\hat{\theta}^{(m)}, \mathbf{x}} \left\{ \log \left[ \frac{k(\mathbf{Z}|\hat{\theta}^{(m+1)}, \mathbf{x})}{k(\mathbf{Z}|\hat{\theta}^{(m)}, \mathbf{x})} \right] \right\} &\leq \log E_{\mathbf{z}|\hat{\theta}^{(m)}, \mathbf{x}} \left[ \frac{k(\mathbf{Z}|\hat{\theta}^{(m+1)}, \mathbf{x})}{k(\mathbf{Z}|\hat{\theta}^{(m)}, \mathbf{x})} \right] \\ &= \log \int \frac{k(\mathbf{z}|\hat{\theta}^{(m+1)}, \mathbf{x})}{k(\mathbf{z}|\hat{\theta}^{(m)}, \mathbf{x})} k(\mathbf{z}|\hat{\theta}^{(m)}, \mathbf{x}) d\mathbf{z} \\ &= \log(1) \\ &= 0 \end{aligned} \quad (6.6.10)$$

よって，(6.6.9) が成立する．以上から，定理の結果を得る．  $\square$

例 6.2.  $Y_1 \sim N(\mu_1, \sigma_1^2), Y_2 \sim N(\mu_2, \sigma_2^2), W \sim \text{Bin}(1, \epsilon), X = (1 - W)Y_1 + WY_2$  とする. ここで,  $W$  は  $Y_1, Y_2$  と独立である. また,  $\boldsymbol{\theta}' = (\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \epsilon)$  とする. 確率変数  $X$  の pdf は

$$f(x) = (1 - \epsilon)f_1(x) + \epsilon f_2(x), \quad -\infty < x < \infty \quad (6.6.17)$$

ただしここで,  $f_j(x) = \sigma_j^{-1} \phi[(x - \mu_j)/\sigma_j]$  である. この pdf を持つ分布からの観測された標本を  $\mathbf{X}' = (X_1, X_2, \dots, X_n)$  と表す. この時, 対数尤度関数は,

$$l(\boldsymbol{\theta}|\mathbf{x}) = \sum_{i=1}^n \log[(1 - \epsilon)f_1(x_i) + \epsilon f_2(x_i)] \quad (6.6.18)$$

となる. この問題において, 観測されないデータは, どの分布に所属するかを表す確率変数である.  $i = 1, \dots, n$  にたいして,

$$W_i = \begin{cases} 0 & \text{if } X_i \text{ has pdf } f_1(x) \\ 1 & \text{if } X_i \text{ has pdf } f_2(x) \end{cases}$$

とする. これらの確率変数は, 成功確率  $\epsilon$  のベルヌーイ分布からの無作為標本 (=iid 標本) である. 完全尤度は,

$$L^c(\boldsymbol{\theta}|\mathbf{x}, \mathbf{w}) = \prod_{W_i=0} f_1(x_i) \prod_{W_i=1} f_2(x_i)$$

であり, 完全尤度の対数をとると,

$$\begin{aligned} l^c(\boldsymbol{\theta}|\mathbf{x}, \mathbf{w}) &= \sum_{W_i=0} \log f_1(x_i) + \sum_{W_i=1} \log f_2(x_i) \\ &= \sum_{i=1}^n [(1 - w_i) \log f_1(x_i) + w_i \log f_2(x_i)] \end{aligned} \quad (6.6.19)$$

となる. *Estep* のために,  $\mathbf{x}, \boldsymbol{\theta}_0$  を与えたもとの  $W_i$  の条件付き期待値,

$$E_{\boldsymbol{\theta}_0}[W_i|\boldsymbol{\theta}_0, \mathbf{x}] = P[W_i = 1|\boldsymbol{\theta}_0, \mathbf{x}]$$

が必要である. この期待値の推定値として,  $x_i$  が分布  $f_2(x)$  からの標本であるとした時の尤度,

$$\gamma_i = \frac{\hat{\epsilon} f_{2,0}(x_i)}{(1 - \hat{\epsilon}) f_{1,0}(x_i) + \hat{\epsilon} f_{2,0}(x_i)} \quad (6.6.20)$$

を利用可能である. ただし, 添字の 0 はパラメータ  $\boldsymbol{\theta}_0$  とした時の分布が利用されたことを示している. (6.6.19) の  $w_i$  を  $\gamma_i$  に置き換えると, *Mstep* では,

$$Q(\boldsymbol{\theta}|\boldsymbol{\theta}_0, \mathbf{x}) = \sum_{i=1}^n [(1 - \gamma_i) \log f_1(x_i) + \gamma_i \log f_2(x_i)] \quad (6.6.21)$$

を最大化すれば良いということがわかる．この最大化は，各パラメータに関して， $Q(\boldsymbol{\theta}|\boldsymbol{\theta}_0, \boldsymbol{x})$  を微分した際の停留点を更新式として利用すれば達成される．色々省くが，それぞれの更新式は，

$$\begin{aligned}\hat{\mu}_1 &= \frac{\sum_{i=1}^n (1 - \gamma_i) x_i}{\sum_{i=1}^n (1 - \gamma_i)} \\ \hat{\sigma}_1^2 &= \frac{\sum_{i=1}^n (1 - \gamma_i) (x_i - \hat{\mu}_1)^2}{\sum_{i=1}^n (1 - \gamma_i)} \\ \hat{\mu}_2 &= \frac{\sum_{i=1}^n \gamma_i x_i}{\sum_{i=1}^n \gamma_i} \\ \hat{\sigma}_2^2 &= \frac{\sum_{i=1}^n \gamma_i (x_i - \hat{\mu}_2)^2}{\sum_{i=1}^n \gamma_i} \\ \hat{\epsilon} &= \frac{1}{n} \sum_{i=1}^n \gamma_i\end{aligned}$$

となる．これを収束するまで更新し続ける．

**例 6.3.** 上の更新式を導出してみましょう．

解答





## 6.0 付録：正則条件

正則条件をまとめておく．

6 章で用いる正則条件

(R0) pdf が全く異なる (distinct), つまり,  $\theta \neq \theta' \Rightarrow f(x; \theta) \neq f(x; \theta')$

(R1) pdf が任意の  $\theta$  に関して共通の台 (support) を持つ

(R2) 点  $\theta_0$  が  $\Omega$  の内点 (interior point) である

(R3) pdf  $f(x; \theta)$  が  $\theta$  の関数として, 二回微分可能

(R4) 積分  $\int f(x; \theta) dx$  が  $\theta$  の関数として, 二回微分可能

(R5) pdf  $f(x; \theta)$  が  $\theta$  の関数として三回微分可能であるとし, さらに, 任意の  $\theta$  について,

$$\left| \frac{\partial^3}{\partial \theta^3} \log f(x; \theta) \right| \leq M(x)$$

$$E_{\theta_0}[M(X)] < \infty, \forall \theta_0 - c < \theta < \theta_0 + c, \text{ and all } x \text{ in the support of } X$$

なる定数  $c$ , 関数  $M(x)$  が存在する.

(R6)  $\theta_0 \in \Omega_0$  なる開部分集合  $\Omega_0 \subset \Omega$  が存在して, 任意の  $\theta \in \Omega_0$  に対して, pdf  $f(x; \theta)$  の全ての 3 階偏微分が存在する

(R7) 以下の方程式

$$E_{\theta} \left[ \frac{\partial}{\partial \theta_j} \log f(x; \theta) \right] = 0, \text{ for } j = 1, \dots, p$$

$$I_{jk}(\theta) = E_{\theta} \left[ \frac{\partial^2}{\partial \theta_j \partial \theta_k} \log f(x; \theta) \right], \text{ for } j, k = 1, \dots, p$$

が成立する (期待値作用素 (=積分) と微分の順序交換が可能である).

(R8) 任意  $\theta \in \Omega_0$  に対して,  $\mathbf{I}(\theta)$  が正定値

(R9) 以下を満たすような

$$\left| \frac{\partial^3}{\partial \theta_j \partial \theta_k \partial \theta_l} \log f(x; \theta) \right| \leq M_{jkl}(x), \forall \theta \in \Omega_0$$

$$E_{\theta_0}[M_{jkl}] < \infty, \forall j, k, l \in 1, \dots, p$$

関数  $M_{jkl}(x)$  が存在する.

(いつみても多い...!!!)